



Detección de estructuras musicales utilizando análisis de señales y representaciones visuales

Leonel Sebastián Martínez

Seminario Final

2023

Abstract

La presente investigación propone el análisis e identificación de la estructura interna de una pieza musical a partir de la utilización de matrices de similitud conformadas desde la transformación de una señal de audio. La técnica aplicada se centra en el entendimiento de la forma en la que los seres humanos percibimos el sonido, y cómo cognitivamente somos capaces de distinguir patrones a partir de aspectos tanto musicales como de fenómenos físicos. La contribución principal de este trabajo radica en la construcción de un método replicable en el que no sólo se persigue el análisis de una pieza musical de manera abstracta, sino que también se traduce en imágenes al aplicar, en una segunda instancia, técnicas de segmentación y visualización que permitan comunicar de manera clara los resultados obtenidos.

Table of Contents

Introducción	1
Antecedentes	1
Metodología	2
Discretización de la señal de audio	3
Detección de secciones	4
Generación de matrices de propia similitud	4
Novelty score	6
Segmentación y preparación de features	8
Clustering	9
Visualización y comunicación de resultados	11
Conclusiones	12

Introducción

La detección automática de patrones es un campo de estudio aplicable a infinidad de casos de diversa naturaleza. Puntualmente en medios audiovisuales resulta especialmente útil para analizar la composición interna de un video o una pieza musical, desde el conteo de acciones repetitivas que allí se muestren¹ hasta el estudio de la composición musical de una canción². Desde el punto de vista de este último, el desafío que se presenta es la capacidad de traducir las normas subjetivas involucradas en la percepción e identificación de segmentos musicales al campo de lo matemático, resultando imperativa la comprensión de conceptos cruciales como la armonía, el ritmo y el timbre que direccionan en todo momento la construcción de la metodología aquí propuesta.

A través de la utilización de *matrices de similitud* es posible analizar una pista de audio autorreferenciandola con sí misma para detectar segmentos de características similares, por lo cual el *framework* desarrollado se basa en una aproximación heurística que busca generalizar el proceso, y siendo capaz de aplicarse sobre cualquier canción, sin importar género, tempo, duración o instrumentación, al ser una implementación de aprendizaje no supervisado.

En segunda instancia, se propone además una visualización de las secciones halladas.

Antecedentes

El propósito de este trabajo es proporcionar a los músicos una herramienta que les permita comprender y memorizar de manera eficiente la estructura interna de una canción. A través de un enfoque basado en el análisis de patrones de repetición en una pista de audio, se busca ofrecer un apoyo visual que facilite la interpretación musical. Este proyecto, entonces, se enmarca en la creciente intersección entre la música y la tecnología, haciendo uso de las ventajas que el desarrollo de la ciencia de datos presenta y el procesamiento de señales para mejorar la experiencia musical.

En este sentido, se destaca la significativa contribución de Job Savelsberg, quien ha centrado su investigación en el mismo ámbito, pero con un enfoque colocado en los datos proporcionados por la API de Spotify³. Estos datos ya han sido previamente procesados por una herramienta de análisis que detecta diversas características de una canción, tales como el timbre, la tonalidad, los acordes, la intensidad y las secciones, entre otros aspectos. Su estudio se fundamentó en la identificación de patrones estructurales mediante la utilización de múltiples de estas características, y empleó una combinación de enfoques metodológicos para obtener las clasificaciones deseadas. Es importante

¹Dwibedi, D. (2020, June 27). *Counting Out Time: class agnostic video repetition Counting in the wild*. arXiv.org. <https://arxiv.org/abs/2006.15418>

²(2020, May 14). https://wlouie1.github.io/MusicPlot/musicplot_paper.pdf

³Savelsberg J. (2001). Visualizing music structure using Spotify data. In *Extended Abstracts for the Late-Breaking Demo Session of the 22nd Int. Society for Music Information Retrieval Conf. (ISMIR EA)*.

señalar que su investigación no se basa en el análisis directo de las señales de audio, ya que la API de Spotify convierte todos estos datos en un formato de texto plano, específicamente en formato JSON. En contraste con esta aproximación, el presente estudio se centrará en la aplicación de métodos de clasificación no supervisada como se ha mencionado, explorando en su lugar señales de audio en la búsqueda de una mejora en el proceso.

Varios autores han propuesto la utilización de *matrices de similitud*⁴⁵⁶ dada la facilidad de interpretación que provee visualmente, y varias de las técnicas allí aplicadas se retomarán en este trabajo. Fundamentalmente, se parte desde una señal discreta, se la transforma al procesar un aspecto puntual del sonido obteniendo un espectrograma (frecuencia e intensidad) o un cromagrama (altura tonal e intensidad), para luego generar la matriz de similitud en base a este paso intermedio y la posterior delimitación de las secciones, seguido de una etapa de *clusterización* para finalmente encontrar las similitudes entre ellas.

A diferencia de lo desarrollado hasta el momento, este trabajo persigue la construcción de una herramienta que cubre la totalidad del espectro de acción, partiendo desde un archivo de audio hasta la elaboración de la visualización, aspectos que históricamente se han tratado por separado.

Metodología

Los caminos de abordaje para la resolución de esta problemática se caracterizan por presentar una idea general común en la mayoría de los estudios realizados hasta el momento, diferenciándose entre sí al aplicar variaciones y enfoques distintos en la ejecución de cada uno de los pasos intermedios⁷⁸.

Puntualmente, en el presente trabajo se utiliza la metodología de Foote⁹ para construir las bases del *framework* y se exploran algunas variaciones inspiradas en investigaciones posteriores con el fin de detectar los puntos clave que presentan el mayor potencial de mejora.

⁴(2020, May 14). https://wluoie1.github.io/MusicPlot/musicplot_paper.pdf

⁵Foote, J. (2000, July 1). *Automatic audio segmentation using a measure of audio novelty*. IEEE Xplore. <https://doi.org/10.1109/ICME.2000.869637>

⁶Hirai, T., & Sawada, S. (2019). Melody2Vec: Distributed Representations of Melodic Phrases based on Melody Segmentation. *Journal of Information Processing*, 27(0), 278–286. <https://doi.org/10.2197/ipsjip.27.278>

⁷Nieto, O., Mysore, G. J., Wang, C., Smith, J. B. L., Schlüter, J., Grill, T., & McFee, B. (2020). Audio-Based Music Structure Analysis: Current trends, open challenges, and applications. *Transactions of the International Society for Music Information Retrieval*, 3(1), 246–263. <https://doi.org/10.5334/tismir.54>

⁸Tralie, C. J., & McFee, B. (2019). *Enhanced Hierarchical Music Structure Annotations via Feature Level Similarity Fusion*. <https://doi.org/10.1109/icassp.2019.8683492>

⁹Foote, J. (2000, July 1). *Automatic audio segmentation using a measure of audio novelty*. IEEE Xplore. <https://doi.org/10.1109/ICME.2000.869637>

Discretización de la señal de audio

Para realizar un análisis matemático a partir de algún aspecto específico del audio, es necesario convertir la señal y trasladarla numéricamente a un dominio que posibilite esta tarea. Es por ello que en este primer paso se calculan el espectrograma y el cromagrama, dos representaciones de la señal de audio en función del tiempo.

Específicamente, el espectrograma representa la energía de la señal en función de la frecuencia y el tiempo, mientras que el cromagrama la representa en función de la frecuencia **musical** (altura tonal) y el tiempo. Ambos enfoques añaden una dimensión diferente, dado que el primero facilita el estudio del espectro del sonido asociado a los diferentes instrumentos que se ejecutan, mientras que el segundo permite analizar la composición musical a cada momento independientemente del instrumento que está generando el sonido. Es decir, a través del espectrograma se detecta cuál la fuente, y a través del cromagrama qué es lo que está tocando.

Para calcular el espectrograma, se divide la señal de audio en ventanas de tiempo de longitud fija. Luego se aplica una transformada de Fourier a cada ventana para obtener su espectro por frecuencia, y por último se genera el espectro completo en el dominio del tiempo al concatenar la totalidad de las ventanas.¹⁰

Para calcular el cromagrama, se realiza el mismo procedimiento que para el espectrograma, con la distinción de que luego de aplicar la transformada de Fourier se agrupan las bandas por altura tonal, obteniendo la energía asociada a cada una de ellas.¹¹




Figure 1: Espectrograma de “Dua Lipa - Fever”.

La elección de estas dos dimensiones no es casual. Las características principales de las composiciones musicales se encuentran asociadas a la armonía, la melodía y el ritmo. De los tres conceptos, el más sencillo de interpretar y representar es la armonía, ya que este se explica a través de la sucesión de acordes (notas musicales ejecutadas al mismo tiempo). En el contexto de este trabajo, los segmentos

¹⁰Bracewell, R. N. (1965). *The Fourier Transform and its applications*. <http://cds.cern.ch/record/103847>

¹¹Stevens, S. S., & Volkman, J. (1940). The Relation of Pitch to Frequency: A Revised scale. *American Journal of Psychology*, 53(3), 329. <https://doi.org/10.2307/1417526>




Figure 2: Cromagrama de “Dua Lipa - Fever”.

musicales se caracterizan por sucesiones de acordes similares, por lo que el cromagrama resulta en una traducción numérica directa de este concepto.

Por otro lado, auditivamente ocurre que cada segmento de una canción contiene una instrumentación y una dinámica de intensidad diferentes, por lo cual los cambios espectrales generalmente indican transiciones.

Detección de secciones

Generación de matrices de propia similitud

El paso más relevante y de mayor impacto sobre la totalidad del *framework* es la elección del criterio a utilizar para la detección de los segmentos en sí mismos. El recurso más utilizado y considerado el más eficiente, continúa siendo a día de hoy el propuesto por Foote¹² mediante la construcción de matrices de propia similitud debido a su alta efectividad y fácil interpretación.

Las matrices de propia similitud son una representación gráfica de secuencias similares dentro de una serie de datos¹³. Comparando las distancias entre cada uno de los vectores de características obtenidos que componen al espectrograma o el cromagrama con los restantes (y contra sí mismos, en cuyo caso la distancia es siempre nula), se obtiene una matriz simétrica de dimensión $S \times S$, siendo S el número de *samples* de la señal de audio utilizado para el cromagrama y/o espectrograma, y cuyos valores individuales son las distancias calculadas.

Visualmente se observa que se forman bloques dentro de la matriz. Recordando que la misma es simétrica, recorrerla sobre el eje horizontal presenta el mismo efecto que sobre el eje vertical; en este sentido, si la recorremos horizontalmente y nos encontramos con un conjunto de coordenadas con una intensidad de color similar a la misma altura (eje vertical), significa que dichos bloques presentan

¹²Foote, J. (2000, July 1). *Automatic audio segmentation using a measure of audio novelty*. IEEE Xplore. <https://doi.org/10.1109/ICME.2000.869637>

¹³Self-similarity matrix - HandWiki. (n.d.). Handwiki.org. Retrieved December 1, 2023, from https://handwiki.org/wiki/Self-similarity_matrix#:~:text=In%20data%20analysis%2C%20the%20self-similarity%20matrix%20is%20a




Figure 3: Matriz de propia similitud calculado a partir de un cromagrama.




Figure 4: Matriz de propia similitud calculado a partir de un espectrograma.

características similares. Adicionalmente, al desplazarse desde el origen hacia la esquina opuesta sobre la diagonal, se detecta el inicio y el fin de cada uno de los bloques¹⁴. Por tal motivo, mientras más grande sea la diferencia entre los vectores, mayor contraste se observará en el gráfico producido.

Para el caso particular de este trabajo se optó por utilizar la matriz de propia similitud derivada del espectrograma luego de aplicar una reducción en la definición calculando la media de cada posición al agrupar *samples* por el equivalente a un segundo, ya que el contraste entre las potenciales secciones detectadas es más notorio, lo cual es razonable dado que se cuenta con una mayor cantidad de información (128 bandas por muestra) y que, como se ha mencionado, es usual que la instrumentación (y la energía, además del espectro acústico) usualmente cambie abruptamente entre cada segmento de una misma canción. Esta correlación se asume a partir del entendimiento de la dinámica de las composiciones musicales desde una óptica meramente artística, entendiendo que es un recurso vastamente utilizado para mantener la atención del oyente en todo momento.




Figure 5: Matriz de propia similitud con definición reducida.

Novelty score

La metodología que continúa aún vigente es la propuesta por Foote¹⁵. En ella, y tomando en consideración las menciones realizadas con respecto a las matrices de propia similitud en la subsección

¹⁴(2023). Covers1000.net. <https://www.covers1000.net/GraphDitty/>

¹⁵Foote, J. (2000, July 1). *Automatic audio segmentation using a measure of audio novelty*. IEEE Xplore. <https://doi.org/10.1109/ICME.2000.869637>

anterior, se recurre a la utilización de un kernel que, al desplazarlo a través de la diagonal desde el origen hasta el extremo opuesto, evalúa a cada paso el grado de “novedad” de la pieza al interpretar numéricamente la diferencia entre los cuatro cuadrantes que posee, en un intento por detectar cambios abruptos en el espectro caracterizados por la formación de una cruz teniendo como centro el punto específico en donde ocurre dicho cambio.

Para ello se utiliza un kernel con un patrón de tablero de ajedrez (se suman los valores de los cuadrantes 1 y 3, y se restan los cuadrantes 2 y 4) al que se le aplica una distribución gaussiana para enfatizar las regiones cercanas a la diagonal y suavizar los extremos.




Figure 6: Kernel de patrón de ajedrez con taper gaussiano.

Dependiendo del tamaño de esta matriz se podrán delimitar eventos de mayor o menor *granularidad* o jerarquía, desde la detección de compases al tener la resolución más pequeña posible (matriz de 2×2), a secciones enteras pertenecientes a la estructura propia de una canción al capturar una mayor cantidad de *samples* al mismo tiempo dentro de la matriz de propia similitud. En este sentido, el tamaño del kernel debe estar relacionado, idealmente, al tempo de la canción, que dependiendo de la resolución en la que se haya capturado el audio va a permitir detectar con mayor precisión (y la menor carga computacional posible) los bordes de cada segmento.

Para este trabajo se optó por utilizar un kernel relativamente pequeño que no supere un veinteavo del total de *samples*, lo que genera multitud de picos en el gráfico de variada altitud dependiendo

del grado de “novedad” encontrado, por lo que se estableció un *threshold* a partir del cual el pico se considera relevante para la segmentación.




Figure 7: Novelty scores superpuestos para kernels de 100 y 200 samples.

El umbral se estableció en 0.4 considerando que un número menor captaría variaciones en la estructura de una jerarquía más específica a la esperada.




Figure 8: Umbral aplicado sobre el novelty score.

Segmentación y preparación de features

Luego de detectar todos los puntos en el tiempo relevantes para la segmentación, se procede al siguiente paso que consiste en representar en vectores de características a cada una de las secciones encontradas, posibilitando una comparación de ellas entre sí para determinar su similitud.

Si previamente se había comentado la elección de la totalidad del espectro sonoro como un indicador suficiente para detectar cambios notorios en una canción, de igual manera se mencionó que los cromagramas expresan correctamente la estructura musical independientemente de los instrumentos

que se estén ejecutando. Teniendo en cuenta esta distinción, se entiende que generalmente las secciones de una canción se dividen de acuerdo a grupos de repeticiones armónicas, y evaluar esta dimensión resulta comprensible y necesaria.

Es así como cada punto relevante detectado a lo largo de la diagonal de la matriz de propia similitud se transforma en un punto de referencia y, regresando al cromagrama original previamente calculado, se lo divide internamente en cada una de las potenciales secciones encontradas indicadas por los picos del *novelty score*.




Figure 9: Cromagrama con divisiones encontradas.

Una vez indexados los grupos como bloques entre cada división, se calculan las *features* de cada segmento como la media del valor en cada banda. Esta acción posee el mismo impacto que calcular el cromagrama con ventanas de tiempo de tamaño variable. A pesar de la representación visual expuesta, la nueva matriz obtenida posee tantas entradas como secciones detectadas, siendo la única característica analizada la energía de las alturas tonales que la componen.




Figure 10: Cromagrama segmentado.

Clustering

La última instancia del *framework* propuesto en este trabajo se refiere a la comparación de las secciones identificadas para encontrar similitudes entre ellas. En este punto se cuenta con la representación

matricial calculada en el paso anterior y, como método de clusterización, se eligió el jerárquico aglomerativo.




Figure 11: Representación visual las características de cada segmento.

Por la cantidad de datos presentes a la hora de ejecutar la clusterización, la elección de un método u otro se reduce a unas pocas diferencias conceptuales que no provocan cambios radicales en el resultado final. Sí se destaca la robustez del clustering jerárquico aglomerativo frente a *outliers* a diferencia de métodos más tradicionales como k-means. Debido a su naturaleza, permite, en cierto sentido, ver e interpretar los resultados a cada paso de la clusterización mediante el dendograma y ordenar las secuencias de datos analizados, promoviendo su popularidad en ámbitos como la genética o la química¹⁶, sumado a que no es necesario conocer o estimar *a priori* la cantidad de clusters que deben hallarse.

En esta aplicación, se definieron los parámetros mediante experimentación, encontrando que la combinación de *linkage ward* y distancia euclídea resulta la más óptima, eligiendo el número de clusters a partir del puntaje obtenido por Silhoutte evaluado para cantidades entre 3 y 10. Las canciones por lo general cuentan con al menos un verso, un estribillo y una sección instrumental, justificando la elección de un mínimo de tres. Por el contrario, al presentar un *framework* susceptible a cambios bruscos en el espectro sonoro, puede ocurrir que se detecten secciones de menor jerarquía a la esperada, en cuyo caso un máximo de 10 aporta un pequeño margen para encontrar similitudes en estas micro secciones

¹⁶Corpet, F. (1988). Multiple sequence alignment with hierarchical clustering. *Nucleic Acids Research*, 16(22), 10881–10890. <https://doi.org/10.1093/nar/16.22.10881>




Figure 12: Secciones ordenadas de acuerdo al orden de clusterización.

que tal vez no se deberían haber detectado en primer lugar.

Visualización y comunicación de resultados

Ningún análisis, por más exhaustivo que sea, alcanza verdaderamente su valor si el resultado no puede comunicarse efectivamente. Es por ello que el presente trabajo propone en esta etapa final una forma de presentar las características halladas del audio procesado, simplificando y condensando en color y forma los aspectos del sonido estudiados con el objeto de facilitar su comprensión e interpretación incluso para un público sin los conocimientos técnicos necesarios para la completa comprensión de este desarrollo.

La estrategia empleada recurre a la representación visual de una línea de tiempo segmentada en todas las secciones encontradas, empleando color para identificar qué bloques son similares entre sí (mismo cluster, mismo color) y desplazándolas a lo largo del eje vertical de acuerdo a la media de la intensidad del sonido (*loudness*) que presentan. Para facilitar la legibilidad, se normalizaron dichos valores para que se expresen siempre en una escala entre 0 y 1, y se los redondeó a un único decimal.




Figure 13: Visualización final de características extraídas

Conclusiones

El framework propuesto arroja resultados acordes a lo esperado. Al observar el timeline final, puede observarse que se detectan más segmentos de los reales, pero aun así la robustez de la visualización permite que la comprensión de la estructura interna continúe siendo efectiva, incluso dando lugar a que los “errores” no aporten ruido excesivo y que se visibilicen patrones de repetición. Al contar con una variedad enorme de pasos intermedios a considerar, posee el potencial de utilizarse como base para la experimentación y mejora de cada aspecto, concepto y elección tomada.